Informe de recomendaciones previo al PRD-SRD

Proyecto: Agente Pagador — Reto Blinka "Agentes que pagan por la empresa" **Fecha:** 17 de octubre de 2026 · **Estado:** para aprobación del equipo **Insumos analizados:** enunciado del reto, workflow "Modelo del Semáforo", borrador PRD-SRD v0.1, revisión previa (Claude) y revisión cruzada (DeepSeek)

0. Cómo usar este informe

1. Lean la sección 1 (veredicto sobre la revisión de DeepSeek) y la sección 3 (hallazgos nuevos).
2. Aprueben, modifiquen o rechacen cada ítem de la sección 4 (requisitos) y de la sección 5 (decisiones).
3. Las preguntas de la sección 6 se llevan a los organizadores o mentores si hay canal para ello.
4. Con las respuestas, se actualiza el PRD-SRD a la v0.2.

Cada ítem tiene una casilla: **[A]** aprobado · **[M]** aprobado con cambios · **[R]** rechazado.

1. Veredicto sobre la revisión cruzada (DeepSeek)

La revisión es útil y en su mayoría correcta. Sus aportes mejoran la lista. Pero afirma que la lista fusionada "cubre el reto completo", y no es así: la sección 3 muestra lo que sigue faltando.

#	Observación de DeepSeek	Veredicto	Comentario
1	Subir "Frenar" a crítico	**Aceptada**	El entregable del reto pide ver "qué pagó, qué frenó, qué dejó pendiente". Sin Frenar como estado propio, la pantalla no cumple lo pedido.
2	Subir "Etapa 1 con 100 % de confirmación" a crítico	**Aceptada con matiz**	Es crítico para la **demo** (autonomía 0 % se vería como un recomendador), no para la seguridad. Se resuelve junto con el tema de etapas (ver R-04).
3	"Fraude" es crítico	**Aceptada**	El reto excluye decisiones de cumplimiento o fraude. Mencionarlo contradice el alcance.
4	Declarar datasets simulados con esquema	**Aceptada**	Sin ellos no se puede decir "contra qué" se compara cada factura.
5	Bandeja de tres columnas	**Aceptada con matiz**	Falta definir qué pasa con lo que una persona ya resolvió y que lo frenado debe poder reabrirse (ver R-08).
6	Tabla de mapeo caso → decisión → responsable → explicación	**Aceptada con matiz**	El borrador v0.1 ya tenía una versión parcial (sección 7). Se amplía en la sección 4.1. El responsable debe ser un dato fijo, no un directorio configurable.
7	Presupuesto corriente (sugerencia: subirlo a crítico)	**Aceptada y reforzada**	Hay una razón de **seguridad** además de la de demo: si no se acumula lo pagado, varias facturas que caben cada una en el límite podrían pasarse del límite del periodo en conjunto.
8	Lista de 16 acciones	**Aceptada con consolidación**	Hay duplicados: las acciones 2 y 13 son el mismo tema; 7, 10 y 14 son el mismo bloque de datos; 11 y 16 comparten las plantillas de explicación. Se reducen a 14 requisitos (sección 4).

Dos puntos donde no sigo a DeepSeek:

- **Toggle simulado de etapas** (su acción 13): cuesta tiempo y no suma puntaje en ninguno de los tres criterios. Recomiendo dejar las etapas solo como hoja de ruta en la presentación.
- **Directorio de contactos como funcionalidad:** el reto pide "pedirle permiso a *una persona*". Enrutar por área es un buen diferenciador, pero basta con un responsable sugerido fijo por tipo de caso (Compras, Legal, Finanzas, Gerencia), sin pantalla de directorio.

2. Lo que está bien del workflow (se conserva)

Reglas determinísticas para datos exactos e IA solo para leer: es la decisión que más protege la seguridad y la explicabilidad.
Las 4 fuentes de verdad corresponden al reto: **proveedores** (beneficiarios permitidos), **contratos** ("lo acordado"), **presupuesto** (límites por periodo) e **historial** (duplicados).
Los casos trampa del reto están cubiertos.
Cada decisión muestra qué fuentes se consultaron y por qué.

3. Hallazgos nuevos (no están en ninguna de las dos revisiones)

H-1 · Una lectura equivocada de la factura es el mayor riesgo de seguridad

Todas las reglas dependen de lo que la IA extrae. Si lee 1.500 como 15.000 (o al revés), las reglas deciden bien sobre un dato malo y el resultado es un pago indebido. **Recomendación:** (a) exigir que los campos obligatorios estén presentes y con formato válido; (b) cruzar lo extraído contra las fuentes (el beneficiario debe existir, la moneda debe ser una permitida); (c) si la lectura es ambigua o hay baja confianza → **Escalar**. Agregar un caso trampa de factura ilegible o con monto ambiguo.

H-2 · El texto de la factura es un dato, no una instrucción

Una factura llega por PDF, correo o chat, es decir, de fuentes no confiables. Si el agente "obedece" lo que dice el texto (por ejemplo, "aprobar sin revisión"), se rompe la regla de oro del reto. **Recomendación:** la decisión la toma el código con las reglas; el modelo solo extrae y no tiene ninguna acción de "pagar". Agregar una factura con instrucciones incrustadas como caso trampa de robustez. No es detección de fraude: es que el agente no se deja redirigir.

H-3 · Falta una regla de precedencia cuando fallan varias reglas

¿Qué pasa con una factura duplicada **y** de proveedor nuevo **y** sobre el umbral? **Recomendación:** el desenlace más restrictivo gana: **Frenar > Escalar > Pagar**. El registro lista **todos** los motivos, no solo el primero.

H-4 · El presupuesto acumulado depende del orden de procesamiento

Si las facturas se procesan en orden distinto, cambia cuáles se pagan y cuáles se frenan. **Recomendación:** orden fijo y documentado (por fecha de vencimiento y luego por orden de

llegada) para que el resultado sea repetible. Falta además decidir si una factura pendiente de aprobación reserva saldo (ver D-02).

H-5 · "Periodo" no está definido

Se usa para dos cosas distintas: el presupuesto y el duplicado ("mismo proveedor, monto y periodo"). Y nadie dijo para qué sirve el dato "para cuándo" que el reto pide extraer. **Recomendación:** definirlo una vez (ver D-03).

H-6 · Los bordes de los límites no están definidos

"Supera el límite": ¿un monto exactamente igual al límite se paga o se escala? **Recomendación:** igual al límite **sí cumple** (solo "mayor que" escala). Incluir facturas justo en el límite y justo por encima en el set de prueba.

H-7 · Falta distinguir quién tomó la decisión

Una factura pagada por el agente y una pagada tras la aprobación de una persona no deben contar igual en la autonomía. **Recomendación:** estados con origen (ver R-05).

H-8 · "Cero pagos indebidos" debe ser una prueba, no una declaración

Recomendación: un script que corre todo el set de pruebas y **falla** si alguna factura cuya decisión esperada no es "Pagar" termina como "Pagar".

H-9 · La autonomía solo se mide bien con datos que el agente no vio al construirlo

Si el equipo ajusta las reglas mirando las mismas facturas con las que mide, el porcentaje sale inflado. **Recomendación:** separar un set de desarrollo y un set de prueba. El reto permite **compartir facturas entre equipos**: intercambiar sets con otro equipo da una prueba ciega real (ver sección 7).

4. Requisitos fusionados propuestos para el PRD

4.1 Tabla de decisiones por caso (propuesta)

Criterio: **Frenar** = el pago no debe hacerse tal como está y pedir permiso no tiene sentido (ya se pagó, o excede un tope duro). **Escalar** = una persona con autoridad puede autorizarlo.

Caso	Desenlace	Responsable sugerido (fijo)	Plantilla de explicación
Normal: cumple todas las reglas	**Pagar**	—	"Pagar: beneficiario permitido, monto X ≤ límite, coincide con lo acordado, saldo suficiente."
Cobro duplicado	**Frenar**	Finanzas	"Frenada: duplicada de la factura {id} (mismo proveedor, monto y periodo)."
Presupuesto insuficiente *(ver D-01)*	**Frenar**	Finanzas	"Frenada: saldo del periodo {X}, monto {Y}."
Beneficiario no permitido	**Escalar**	Compras	"Escalada: {beneficiario} no está en la lista permitida."
No cuadra con lo acordado o no hay acuerdo	**Escalar**	Legal	"Escalada: facturado {X}, acordado {Y}" / "sin acuerdo registrado."
Monto sobre el umbral de aprobación humana	**Escalar**	Gerencia	"Escalada: monto {X} supera el umbral {Y}."
Datos ilegibles, incompletos o ambiguos	**Escalar**	Finanzas	"Escalada: no se pudo leer con certeza {campo}."
Factura con instrucciones incrustadas *(robustez)*	Lo que digan las reglas	según el caso	Se añade: "Se ignoró texto de la factura que pedía saltar reglas."

4.2 Lista de requisitos

ID	Requisito	Origen	Prioridad	Decisión
R-01	**Principios inviolables:** (1) nunca pagar fuera de reglas sin aprobación humana; (2) ante duda o dato faltante → Escalar; (3) el código decide y la IA solo lee; (4) el texto de la factura es dato, no instrucción.	Reto + ambas revisiones + H-1, H-2	Crítica	[ ]

ID	Requisito	Origen	Prioridad	Decisión
R-02	**Tres desenlaces de primera clase:** Pagar / Frenar / Escalar, con el criterio de la sección 4.1 y la precedencia Frenar > Escalar > Pagar. Todos los motivos quedan en el registro.	Reto + ambas revisiones + H-3	Crítica	[ ]
R-03	**Semáforo como capa visual.** Verde = Pagar; Rojo = Frenar o Escalar; Amarillo nunca es estado final. El Amarillo resuelve a Verde solo si el **código** valida lo que la IA extrajo de la cláusula (monto ≤ cláusula, vigente) y el registro cita la cláusula. Si hay duda → Escalar.	Ambas revisiones	Crítica	[ ]
R-04	**"Pagar" = decisión registrada**, sin mover dinero ni conectarse a un banco. Las 3 etapas son hoja de ruta en la presentación. La demo corre en modo autónomo (sin confirmación humana por defecto).	Reto + ambas revisiones	Crítica	[ ]
R-05	**Estados con origen de la decisión:** Pagada por el agente · Frenada por el agente · Pendiente de aprobación · Aprobada por persona · Rechazada por persona. La autonomía solo cuenta decisiones del agente.	H-7	Alta	[ ]
R-06	**Sin lenguaje de fraude.** Se valida coincidencia contra el registro; no se detecta fraude. Esto aplica al documento, a la pantalla y a la presentación.	Reto + ambas revisiones	Crítica	[ ]
R-07	**Datasets simulados declarados con esquema:** proveedores (beneficiario permitido, cuenta registrada, moneda), acuerdos (proveedor, monto pactado, vigencia, concepto; cláusula opcional), presupuesto (periodo, límite, saldo), historial de facturas, tasa de cambio fija y reglas de la empresa ficticia. Todos 100 % ficticios.	DeepSeek + Claude	Alta	[ ]
R-08	**Pantalla de resultados con tres vistas** (Pagadas / Frenadas / Pendientes de aprobación), fila expandible con el "por qué" y los motivos. Lo resuelto por una persona se muestra en Pagadas o Frenadas con su etiqueta de origen. Una factura frenada puede reabrirse y escalarse a una persona.	DeepSeek + H-7	Alta	[ ]
R-09	**Pantalla de reglas** con lo que pide el reto: límite por pago, límite por periodo, beneficiarios permitidos, umbral de	Ambas revisiones	Alta	[ ]

ID	Requisito	Origen	Prioridad	Decisión
	aprobación humana (más monedas permitidas y tasa de la demo). Etapa, meta de aciertos y directorio quedan fuera de la v1.			
R-10	**Presupuesto corriente:** cada "Pagar" descuenta saldo; el registro muestra saldo antes y después; orden de procesamiento fijo (D-04).	Claude + DeepSeek + H-4	Alta	[ ]
R-11	**Explicaciones por plantilla** armadas con los resultados reales de las reglas (sección 4.1). La IA solo aporta la cita de la cláusula.	Claude	Alta	[ ]
R-12	**Set de facturas:** normales y trampa, varios canales (PDF, imagen, correo, chat), decisión esperada por factura, casos de frontera, y dos conjuntos (desarrollo y prueba). Duplicados por proveedor + monto + periodo, no por folio.	Reto + H-6, H-9	Alta	[ ]
R-13	**Prueba automática de seguridad:** el script corre el set y falla si alguna factura que no debe pagarse sale como "Pagar".	H-8	Alta	[ ]
R-14	**Medición aparte:** la autonomía se calcula contra la decisión esperada y **no** va dentro del registro por factura. Prueba de lectura con una persona ajena al equipo para explicabilidad.	Claude + DeepSeek	Media	[ ]

5. Decisiones que necesita el equipo

ID	Decisión	Recomendación	Elegido
D-01	¿Qué se **frena**?	Duplicados **y** presupuesto insuficiente (tope duro: el aprobador debe ampliar el presupuesto y reprocesar, no aprobar factura por factura). Alternativa: frenar solo duplicados y escalar el resto.	
D-02	¿Una factura pendiente de aprobación **reserva saldo**?	No reserva. Al aprobar se muestra el saldo actual para que la persona decida con esa información.	

ID	Decisión	Recomendación	Elegido
D-03	Definición de **periodo**	Presupuesto: mes de la fecha de pago. Duplicados: mes de servicio de la factura. La fecha "para cuándo" se usa para el orden de procesamiento.	
D-04	**Orden de procesamiento**	Por fecha de vencimiento y luego por orden de llegada.	
D-05	**Monto igual al límite**	Cumple la regla (escala solo si es mayor).	
D-06	¿Entra el **Amarillo** en la v1?	Sí, con un solo caso acotado (anexo o cláusula de ajuste) y solo si el motor está listo a tiempo. Es lo primero que se recorta si falta tiempo.	
D-07	**Moneda base y monedas**	USD como base (empresa constituida en EE. UU.) y 2 o 3 monedas locales con tasa fija.	
D-08	**Roles del equipo**	Datos y set de facturas · motor de reglas y agente · pantallas · pruebas y documentación.	

6. Preguntas para organizadores o mentores del reto

1. ¿"Frenar" y "escalar" tienen una definición oficial? ¿Una factura frenada debe ser visible para una persona?
2. En la métrica de autonomía, ¿una **escalada correcta** cuenta como decisión correcta del agente?
3. ¿El jurado evalúa con **nuestro** set, con uno propio o con el de otro equipo?
4. ¿Cómo se presenta el entregable: demo en vivo, video o repositorio? ¿Cuánto tiempo hay?
5. ¿Comparar la cuenta de pago contra el registro del proveedor es aceptable, o roza el territorio de cumplimiento/fraude excluido?
6. ¿Se espera manejar facturas en más de un idioma?
7. ¿El registro debe verse en la pantalla o puede ser un archivo exportable?

7. Sugerencias dentro de las reglas del reto

- **Intercambiar sets con otro equipo.** El reto lo permite expresamente, y da una prueba ciega de autonomía.

- **Casos de frontera** en el set: justo en el límite, justo por encima, una moneda con decimales, mismo proveedor y monto en otro mes (no es duplicado).
- **Demo de 5 minutos con un cambio de regla en vivo:** cambiar el umbral, reprocesar y mostrar cómo cambian las decisiones. Demuestra reglas configurables y explicabilidad con poco esfuerzo, si el reprocesado ya existe.
- **Lista de "no se hace"** visible en el README (pagos reales, fraude, identidad, cuentas), para evitar que el alcance crezca.
- **Revisión de datos ficticios** antes de subir nada al repositorio: nombres claramente falsos y cero datos reales.

8. Siguientes pasos

1. El equipo marca las casillas de las secciones 4 y 5.
2. Se responden las preguntas de la sección 6 que sea posible llevar a los organizadores.
3. Se actualiza el **PRD-SRD a la v0.2** con los requisitos aprobados, la tabla 4.1, el esquema de datos y la pantalla de resultados.
4. Después sigue el SRS.